

文字探勘期末專案

第九組 黃筠茜 江翊瑄 黃任謙 楊鵬慈

報告大綱

01.

研究目標

02.

實作流程

03.

實作細節

04.

研究結果

05.

分工




研究目標

以國家的角度研究美妝市場趨勢

e.g. 銷售量高的市場,季節性熱門品牌商品



02. 實作流程





03.

實作細節

step 1 資料篩選

- 抓取**美妝保健**類, 留下時間、商品、銷售額、銷售量之欄位
- 去除非美妝保養類
- 時間範圍: 1~12月

保留:

第 071 標(1/1)2023/5月IS Leat韓國溫和柔膚潔顏乳(款式隨機)150G一條66元

去除:

(閩)888 0101 A01-(限+3)(2箱)Mixzuzu 膠原蛋白飲 190ml(24瓶/箱)*2

step 2 資料清理

- 使用正規表達式將商品名稱中的雜訊清除
- 清除商品名稱長度 < 4 之資料

長度小於4之資料，無法完整表達其品名及國家或品牌

清理前：

index 195

第 071 標(1/1)2023/5月IS Leat韓國溫和柔膚潔顏乳 (款式隨機)150G一條66元




清理後：

index 195

IS LEAT韓國溫和柔膚潔顏乳 150G

step 3 國家欄位

- 辨別商品名稱中的國家、並獨立出來
('韓國', '日本', '台灣', '保加利亞', '英國', '德國' ...)
清邁 → 泰國



step 4 品牌欄位

- 使用CKIP之斷詞協助找出較頻繁出現之各品牌
- 人工整理、建立品牌列表
- 將品牌獨立出來

name	country	index 195	
IS LEAT溫和柔膚潔顏乳 150G	韓國		

↓

name	country	brand	index 195	
溫和柔膚潔顏乳 150G	韓國	IS LEAT		

step 5 資料整理、填補

- 統一品牌名稱
- 有品牌、無國家者依品牌填入國家

name	country	brand	index 178
怯斑霜		高麗雅娜	

↓

name	country	brand	index 178
怯斑霜	韓國	高麗雅娜 Coreana	

step 6 檢查、清除無效資料

- 無品牌，但筆數多且品名獨特明顯是某品牌的→填補品牌
- 筆數可觀但無國家、品牌之商品→保留
- 清除無效資料(無品牌亦無國家)

index ▲	time	category	name	total_quantity	total_amount	country	brand
1080	2022-01-06 06	[美妝保健]	E BOTANICAL STUDIO 芳香噴霧	6	228	韓國	
1081	2022-01-06 06	[美妝保健]	BK W.LAB 名模具光定妝噴霧 玫瑰金色	7	70	韓國	
1083	2022-01-06 06	[美妝保健]	最新特潤超導賦活精粹 拚网速只要	6	10995	美國	雅詩蘭黛 Estee Lauder
1085	2022-01-06 07	[美妝保健]	頂級酒粕萃取平衡精華 30ML	5	6900	台灣	台酒生技
1088	2022-01-06 07	[美妝保健]	版深層卸妝潔膚水500ML	43	12857	法國	貝膚黛瑪 Bioderma
1090	2022-01-06 07	[美妝保健]	經典潤膚慕斯霜 誇張價	13	5187	美國	契爾氏 Kiehl's
1100	2022-01-06 07	[美妝保健]	山芙蓉草本修護凝膠25ML	7	4193		
1101	2022-01-06 07	[美妝保健]	酒粕精粹極緻青春活膚霜30G	12	33588	台灣	台酒生技
1102	2022-01-06 07	[美妝保健]	BG VIVLAS 唯蘭頌『茶秘』保濕補水面膜 藍色	94	8272	韓國	
1106	2022-01-06 07	[美妝保健]	BA LEBELAGE 眼霜	397	34936	韓國	
1109	2022-01-06 08	[美妝保健]	高機能無瑕水凝乳SP 40ML	5	4935	台灣	台鹽生技
1113	2022-01-06 08	[美妝保健]	BB 保濕亮白精華噴霧	78	23322	韓國	東星 Dongsung
1116	2022-01-06 08	[美妝保健]	櫻花肌齡無痕精華45ML	10	4750	台灣	台鹽生技

BERT 分類模型訓練

step 1 建立訓練資料集

- 從前處理完的資料裡選500筆
- 用GPT初步分類, 再透過人工修正
- 標記好正確答案以用來預測其他商品

運行環境 : Colab GPU

部分訓練資料集擷取

283	雪花秀SULWHASOO珍雪活豐盈泡沫顏潔面乳15ML	洗卸產品	洗面乳
284	DR. MAY美博士B3專業毛孔調理潔顏乳120ML	洗卸產品	洗面乳
285	DARK MAGIC洗臉巾80抽顆	洗卸產品	洗臉巾
286	韓國雪花秀 宮中美容皂50G	洗卸產品	美容皂
287	SODA BEAUTY炭酸抗痘潔顏慕斯	洗卸產品	潔顏慕絲
288	SODA BEAUTY炭酸抗痘潔顏慕絲	洗卸產品	潔顏慕絲
289	GUCCI 眉筆 950	眉眼彩妝	眉筆
290	玩眉心機三角眉筆 EYEBROW PNCIL	眉眼彩妝	眉筆
291	玩眉心機三角眉筆 EYEBROW PNCIL咖	眉眼彩妝	眉筆
292	玩眉心機三角眉筆 EYEBROW PNCIL灰咖	眉眼彩妝	眉筆
293	BOBBI BROWN LUXE EYE SHADOW MOONSTONE 5G	眉眼彩妝	眼影
294	BOBBI BROWN 時尚元素系列眼影盤	眉眼彩妝	眼影
295	NARS 眼影盤 甜甜價+1	眉眼彩妝	眼影
296	NARS眼影盤	眉眼彩妝	眼影
297	PIPL 小羊皮眼線筆 01BLACK 1ML 4支	眉眼彩妝	眼線筆
298	蘭蔻睫毛膏組合	眉眼彩妝	睫毛膏
299	AROMAYUR亞瑪迪靈眸先瞇大眼睫毛膏 3支	眉眼彩妝	睫毛膏
300	NOVO幻彩小細管睫毛膏黑色	眉眼彩妝	睫毛膏
301	靈動卷翹睫毛膏	眉眼彩妝	睫毛膏
302	火山泥固體面膜	面膜	火山泥面膜
303	24K黃金安瓶面膜	面膜	面膜
304	面膜3片一組	面膜	面膜
305	4231242 面膜T	面膜	面膜

BERT 分類模型訓練

step 2 建立模型

- 把大小類的名稱轉為encoded整數

```
1 label_encoder = LabelEncoder()  
2  
3 # 將大類和小類分別轉換為整數  
4 selected_columns['大類_encoded'] = label_encoder.fit_transform(selected_columns['大類別'])  
5 selected_columns['小類_encoded'] = label_encoder.fit_transform(selected_columns['小類別'])  
6  
7 name = selected_columns["name"].to_numpy()
```

BERT 分類模型訓練

step 2 建立模型

- 訓練集：驗證集：測試集 = 8：1：1

```
1 # 將資料集分成訓練集（80%）、驗證集（10%）和測試集（10%）
2 train_data, test_data = train_test_split(selected_columns, test_size=0.2, random_state=42)
3 val_data, test_data = train_test_split(test_data, test_size=0.5, random_state=42)
```

- 使用bert-base-chinese model & tokenizer

```
1 # 加載預訓練的BERT模型和tokenizer
2 model = BertForSequenceClassification.from_pretrained('bert-base-chinese', num_labels=715)
3 tokenizer = BertTokenizer.from_pretrained('bert-base-chinese')
```

BERT 分類模型訓練

step 3 模型訓練

- 經過fine-tuning之後訓練，結果如下

```
1 # Example usage:
2 text_to_predict = "胺基酸潔面乳+煙醯胺潔面乳"
3 predicted_large_category, predicted_small_category = predict_category(model, tokenizer, text_to_predict, device)
4
5 if predicted_large_category is not None:
6     print(f'Predicted Large Category: {predicted_large_category}')
7     print(f'Predicted Small Category: {predicted_small_category}')
```

Predicted Large Category: 保養品

Predicted Small Category: 洗面乳

BERT 分類模型應用

使用模型預測其他商品

- 將預測完的結果全數回填至資料中



The screenshot shows a Jupyter Notebook interface with a file named '1 result_df2'. The table contains product data with columns for time, category, name, total_quantity, total_amount, country, and predicted categories (大類別, 小類別, 預測大類別, 預測小類別). The predicted categories are filled in for several rows, indicating the model's output.

	time	category	name	total_quantity	total_amount	country	大類別	小類別	預測大類別	預測小類別
10	2021-12-31 16	['美妝保健']	夜面霜	1	150	日本			護膚	潔顏慕絲
13	2021-12-31 16	['美妝保健']	24K黃金安瓶面膜	9	1692		面膜	安瓶面膜	護膚	潔顏慕絲
15	2021-12-31 17	['美妝保健']	EX亮妍白C	8	2072				眼妝	修護凝膠
19	2021-12-31 23	['美妝保健']	胺基酸潔面乳+煙醣胺潔面乳	1	99				保養品	洗面乳
20	2021-12-31 23	['美妝保健']	遇見誘惑淡香2隻一組	4	556				眼妝	修護凝膠
...	...	...	...	...	...	...	...	...	...	...
39274	2022-03-31 09	['美妝保健']	朝日田野室內擴香膏白小120G	409	15951		香氛	室內擴香膏	眼妝	修護凝膠

Analysis 1 研究銷售額/量最高的國家

- 利用datetime處理日期
- 利用groupby分類統整各國於各月份的資料
- 加總各國每月的total quantity及total amount
- 繪製折線圖觀察趨勢

目的1:

找尋潛在市場

目的2:

時間維度對銷售的影響

Analysis 2 美妝產品大熱品牌

- 排出先前銷售量前四名國家
- 利用groupby分類這四國各品牌各月份的資料並找出銷售量前十名的品牌
- 匯製折線圖
- 利用df.loc找到各品牌的熱門產品

目的:

找出各國最熱門品牌+分析特色

Analysis 3 2023 1月爆牌預測(銷售額最高之品牌)

限制1:

部分品牌銷售紀錄不足



僅預測2022銷售前十的品牌
(確保訓練資料完整)

限制2:

僅有一年的資料
難以觀察季節性



假設沒有季節性, 採用不依賴
季節性的模型

Analysis 3 2023 1月爆牌預測(銷售額最高之品牌)

- 利用groupby分類統整各國品牌於各月份之銷售額
- 找出2022年銷售額前十的品牌
- 分別訓練ARIMA模型和Exponential Smoothing模型並進行隔年1月的銷售額預測
- 選出預測結果前三名的品牌並繪製長條圖
- 比較兩模型的預測結果



04.

研究結果


Result 1 研究銷售額最高的國家

目的1: 找尋潛在市場

韓國美妝第一!

法國產品單價較高的知名品牌,如:迪奧,香奈兒等等,在不景氣的2022就有如此表現,在2024景氣回升可預期將有更多銷量

美國商品銷售額高可歸咎於品牌多樣性,幾乎都是台灣人耳熟能詳的牌子,對於網購不能實體使用這點解決了**產品信任問題**



Result 1 研究銷售量最高的國家


目的2: 時間維度對銷售的影響

7月: 防曬

- 多數皆為韓國防曬商品

11月: 禮盒套裝

- 聖誕交換禮物, 跨年等聚會多



Result 2 美妝產品大熱品牌

目的:找出最熱門品牌+分析特色

韓國Whoo后擁有最顯著的銷售量，

a.商品主打抗老,呼應中高年齡客群

b.如下圖,Whoo后在11月的暢銷產品多為禮盒

天氣丹華炫 蕾絲氣墊粉餅套裝

津率享洗面乳

還幼童眼膏套盒8件組

拱辰享水妍平衡水乳液面霜6件禮盒套組

拱辰享美 平紋潤唇膏3G

拱辰享雪 泡沫洗面乳

拱辰享雪玉凝系列6件禮盒套組


拱辰享美 平紋潤唇膏3G+ 拱辰享美 平紋潤唇膏

天氣丹華炫美肌7件禮盒組



秘帖5件禮盒組

Name: name, dtype: int64

Total Quantity per Month for Top 10 Brands in 韓國



Result 3 2023 1月爆牌預測(銷售額最高之品牌)



分工



資料前處理

江翊瑄、黃任謙



結果分析

黃筠茜、楊鵬慈



簡報

全員



Thanks!